

Clusterização de Perfis de Jogadores da NBA com K-Means

Trabalho 1 — Inteligência Artificial II — 2026/02

Autor: Otávio Ferreira Dahlke - Professor: Rhauani Weber Aita Fazul

Este trabalho aplica aprendizado não supervisionado para segmentar os jogadores da NBA da temporada 2026 a partir de suas estatísticas por jogo.

1. Dataset

O dataset é o NBA Stats (1947-present) mantido no Kaggle por Sumitro Datta (<https://www.kaggle.com/datasets/sumitrodatta/nba-aba-baa-stats/data>), que consolida dados extraídos do site Basketball Reference. O arquivo utilizado é Player Per Game.csv, que contém as médias por jogo de cada jogador em cada temporada. O arquivo cobre múltiplas ligas (NBA, ABA, BAA) e todas as temporadas desde 1947. Após o filtro pela liga NBA restam 31.119 registros. Cada linha representa a média por jogo de um jogador em uma temporada e em um time. As colunas combinam identificadores (player, player_id, season, team, lg, pos) e números de desempenho por jogo: minutos, arremessos convertidos e tentados, aproveitamentos, bolas de três, lances livres, rebotes, assistências, roubos, tocos, erros e pontos.

2. Problema e objetivo

A classificação tradicional de jogadores de basquete em cinco posições (armador, ala-armador, ala, ala-pivô e pivô) nem sempre tem o melhor poder descritivo, visto que em momentos o que o jogador faz em quadra varia bastante da convenção histórica do que a posição faz, então é aberto o espaço para uma segmentação baseada em comportamento estatístico observado.

Dessa forma o objetivo é descobrir, de forma automática e sem supervisão, grupos de jogadores estatisticamente semelhantes na temporada 2026 da NBA, caracterizar o perfil de cada grupo, identificar os jogadores mais representativos de cada um e disponibilizar um mecanismo capaz de posicionar um jogador novo (real ou hipotético) dentro dessa segmentação. O tipo de tarefa de Machine Learning é o aprendizado não supervisionado, especificamente clustering, onde não existe variável-alvo.

3. Exploração e preparação dos dados

3.1 Principais achados da EDA

A exploração inicial mostrou que o arquivo mistura ligas e épocas distintas, que jogadores transferidos aparecem em mais de uma linha na mesma temporada e que apenas dois campos apresentam valores ausentes. Os achados que efetivamente motivaram decisões de preparação estão consolidados na tabela abaixo.

Etapa	Registros	Observação
Base completa (todas as ligas e temporadas)	33.339	Inclui NBA, ABA e BAA desde 1947
Filtro lg == 'NBA'	31.119	Remove ligas não comparáveis
Filtro season == 2026	733	72 jogadores com mais de um registro
Consolidação de jogadores transferidos	601	Mantida apenas as linhas agregadas (2TM, 3TM e 4TM)
Remoção de duplicatas (player + season)	582	19 duplicatas remanescentes removidas
Base final utilizada no modelo	582	582 jogadores únicos

Tabela 1 — Funil de preparação dos dados.

O problema mais relevante detectado foi a presença de jogadores que trocaram de times durante a temporada: 72 jogadores possuíam mais de um registro em 2026. O Basketball Reference registra, para esses casos, uma linha por time mais uma linha agregada identificada como 2TM, 3TM ou 4TM. Manter todas as linhas faria o mesmo jogador ser agrupado várias vezes, o que distorce o peso de atletas com poucas partidas por equipe. O tratamento adotado identifica os jogadores que possuem linha agregada e descarta suas linhas por time individual; em seguida, uma remoção de duplicatas por player + season elimina os 19 casos remanescentes, chegando a exatamente um registro por jogador.

Foram encontrados 54 valores ausentes, concentrados em duas variáveis de aproveitamento: x3p_percent (35 casos) e ft_percent (19 casos). A ausência não é aleatória: ela ocorre quando o jogador não realizou nenhuma tentativa daquele tipo, produzindo uma divisão por zero. Para não introduzir valores ausentes, foi decidido a imputação da mediana. A imputação pela mediana foi preferida a uma imputação por zero porque, neste caso, ausência não equivale a desempenho nulo: o percentual é indefinido, não zero, quando não há tentativas. Imputar 0 inseriria um sinal artificial de baixíssima eficiência exatamente na variável que alimenta o cálculo de distância do K-Means, distorcendo a posição desses jogadores no espaço de características sem base em nenhuma observação real, junto disso, a informação sobre "joga ou não joga de três" já está corretamente capturada pelas variáveis de volume de 3 pontos, que não são imputadas.

A decisão de não remover outliers é assumida, visto que todos são outliers estatísticos legítimos, removê-los eliminaria um dos grupos de maior interesse analítico.

3.2 Seleção de atributos

Foram descartadas as colunas de identificação e administrativas (player, player_id, season, team, lg), que não carregam informação de desempenho, e também a coluna pos, mantida fora do modelo por decisão de projeto. Restaram 16 features numéricas:

Grupo	Variáveis
Minutos	mp_per_game
Arremessos de quadra	fg_per_game, fga_per_game, fg_percent
Bolas de três	x3p_per_game, x3pa_per_game, x3p_percent
Lances livres	ft_per_game, fta_per_game, ft_percent
Ações de jogo	trb_per_game, ast_per_game, stl_per_game, blk_per_game, tov_per_game
Pontuação	pts_per_game

Tabela 2 — Atributos utilizados no agrupamento.

O conjunto mistura variáveis de volume (por jogo) e de eficiência (percentuais), algo que permite ao modelo distinguir, por exemplo, um pivô de alto aproveitamento e baixo volume de um ala de volume médio e aproveitamento menor, distinção que nenhuma das duas famílias de variáveis faria sozinha.

3.3 Transformação e escalonamento

Não houve necessidade de codificação de categorias, já que todas as features são numéricas. O escalonamento, porém, é obrigatório: o K-Means minimiza distância euclidiana, e as variáveis estão em escalas incomparáveis (mp_per_game varia de 0 a ~37, enquanto fg_percent varia de 0 a 1). Sem padronização, os minutos dominariam o cálculo de distância e os percentuais seriam ignorados na prática. Aplicou-se padronização z-score (StandardScaler), que centra cada variável em média 0 e desvio padrão 1. Optou-se por padronização em vez de normalização porque esta última é mais sensível aos outliers preservados.

A ordem das operações é relevante para a reprodutibilidade e para evitar vazamento de informação: imputação primeiro, padronização depois, ambas ajustadas (fit) uma única vez e reaproveitadas (transform) em qualquer dado novo submetido ao modelo.

4. Estratégia experimental

Por se tratar de tarefa não supervisionada, não há rótulo verdadeiro contra o qual medir erro de generalização, e a divisão clássica treino/teste não se aplica da mesma forma. O modelo final é ajustado sobre a totalidade dos 582 jogadores da temporada, o que é a prática usual em clusterização: o objetivo é descrever a estrutura da população analisada, não prever um valor para observações futuras.

Foram treinados 11 modelos independentes, com K variando de 2 a 12, cada um avaliado por Silhouette Score e inércia (soma das distâncias quadráticas intra-cluster). Os resultados completos estão em `outputs/avaliacao_k.csv`.

A coluna pos, mantida fora do treino, é usada depois do agrupamento para verificar se os grupos encontrados correspondem a papéis reconhecíveis no basquete. Trata-se de uma referência independente do processo de otimização, e portanto uma checagem legítima de que o modelo não capturou apenas ruído.

Um jogador hipotético, que não participou do ajuste, é submetido exatamente ao mesmo pipeline (imputação → padronização → predict) para verificar se o modelo atribui um grupo coerente a uma observação inédita. Esse teste desempenha, na prática, o papel de um conjunto de teste mínimo.

A reprodutibilidade é garantida por `random_state = 42` em todos os modelos e por `n_init = 10`, que executa dez inicializações distintas e retém a de menor inércia, reduzindo a chance de convergência para um mínimo local ruim.

5. Modelagem

A escolha do KMeans se justifica pelo formato do problema: as features são todas numéricas e contínuas, espera-se um número moderado de grupos de tamanho comparável, o volume de dados é pequeno (582×16) e a interpretação por centroide é direta, cada grupo é resumido pelo seu perfil estatístico médio. O algoritmo DBSCAN foi testado e o resultado convergiu para apenas dois grupos o que é insuficiente para representar a diversidade de perfis funcionais que o projeto buscava caracterizar.

Hiperparâmetro	Valor	Justificativa
n_clusters	4	Escolhido por interpretabilidade; ver discussão na seção 7
init	k-means++ (padrão)	Inicialização espalhada dos centroides, converge melhor que aleatória
n_init	10	Dez reinicializações; mantém a solução de menor inércia
max_iter	300 (padrão)	Suficiente: convergência ocorre bem antes desse limite
random_state	42	Fixa a semente e torna a execução reprodutível

Tabela 3 — Hiperparâmetros do modelo final.

Foi aplicado `PCA(n_components=2)` exclusivamente para visualização em duas dimensões dos grupos. O PCA não participa do treinamento: o K-Means opera sobre as 16 features padronizadas.

6. Avaliação


Foram usados dois indicadores internos de qualidade de agrupamento:

- **Silhouette Score** (−1 a 1): mede, para cada ponto, quanto ele está mais próximo do próprio grupo do que do grupo vizinho mais próximo. Valores altos indicam grupos compactos e bem separados.
- **Inércia** (soma das distâncias quadráticas ao centroide): mede a compactidade interna. Diminui monotonicamente com K, então só é interpretável pelo formato da curva (método do cotovelo), nunca por seu valor absoluto.


6.1 Comparação entre valores de K

K	Silhouette	Inércia
2 ← maior silhouette	0.3383	5872.21
3	0.2314	4853.47
4 ← modelo final	0.2421	4305.66
5	0.1868	3973.76
6	0.1769	3670.05
7	0.1679	3510.00
8	0.1609	3357.18
9	0.1486	3198.83
10	0.1442	3092.32
11	0.1534	2956.20
12	0.1489	2873.60

Tabela 4 — Silhouette Score e inércia para K de 2 a 12.



O maior Silhouette ocorre em $K = 2$ (0,3383), e não no K adotado. Segundo, a curva não é monotônica: cai em $K = 3$ e volta a subir em $K = 4$ (0,2421), formando um máximo local, antes de decair de forma consistente a partir de $K = 5$.



A curva de inércia, por sua vez, apresenta sua flexão mais visível entre K = 3 e K = 5, sem cotovelo agudo.

6.2 Resultados do modelo final

Indicador	Valor
Número de clusters (K)	4
Jogadores agrupados	582
Silhouette Score	0,2421
Inércia	4.305,66
Variância explicada por PCA1	54,97%
Variância explicada por PCA2	13,50%
Variância explicada pelas duas componentes	68,47%

Tabela 5 — Resumo da avaliação do modelo final.

6.3 Distribuição e perfil médio dos grupos



Cluster	Jogadores	% da base
0	222	38,1%
1	206	35,4%
2	67	11,5%
3	87	14,9%

Tabela 6 — Tamanho dos clusters.

A distribuição é desbalanceada, mas de forma plausível: os dois grupos maiores concentram reservas e jogadores de rotação, enquanto os grupos de especialistas de garrafão e de protagonistas somam pouco mais de um quarto da liga, proporção compatível com a realidade do esporte, em que titulares de alto uso são minoria.

Cluster	MIN	FG	FGA	FG%	3P	AST	STL	BLK	TOV	PTS
0	10,44	1,31	3,00	0,43	0,45	0,90	0,37	0,21	0,49	3,55
1	23,35	3,64	8,16	0,45	1,49	2,40	0,85	0,35	1,20	10,13
2	23,43	3,91	6,83	0,59	0,31	1,84	0,77	0,99	1,27	9,74
3	31,59	7,26	15,38	0,47	2,09	4,94	1,12	0,53	2,44	20,73

Tabela 7 — Perfil médio de cada cluster, algumas estatísticas, médias completas no CSV perfil_clusters.csv.



7. Análise dos resultados

7.1 Interpretação dos clusters

A interpretação foi feita pela leitura dos centroides padronizados (quais variáveis estão acima ou abaixo da média entre grupos).

Cluster		Rótulo interpretativo Assinatura estatística
0 (222)	Reservas de baixa minutagem	10,4 min, 3,6 pts, 3,0 arremessos tentados; todos os indicadores abaixo da média
1 (206)	Jogadores de rotação do perímetro	23,4 min, 10,1 pts, 1,49 bolas de três convertidas, 2,4 assistências; volume médio e perfil de quadra aberta
2 (67)	Especialistas no garrafão	23,4 min, 9,7 pts, FG% = 0,59, 0,99 tocos , apenas 0,31 bolas de três; alta eficiência e volume interno
3 (87)	Protagonistas, jogadores de alta minutagem	31,6 min, 20,7 pts, 15,4 arremessos tentados, 4,9 assistências, 2,4 erros; maior uso ofensivo da liga

Tabela 8 — Caracterização dos quatro grupos.

O achado central é o contraste entre os clusters 1 e 2. Ambos têm praticamente a mesma minutagem (23,4 min) e produção de pontos semelhante (10,1 contra 9,7), de modo que uma segmentação baseada apenas em volume os fundiria. O modelo, no entanto, os separa nitidamente pela forma como esses pontos são obtidos, e outros fatores como tocos e rebotes, o cluster 2 converte 59% dos arremessos, quase não tenta bolas de três (0,31) e dá quase um toco por jogo, ao passo que o cluster 1 converte 45%, acerta 1,49 bolas de três e bloqueia três vezes menos. Essa é exatamente a distinção entre jogo interior e jogo perimetral, recuperada sem que a posição tenha sido fornecida ao algoritmo. A validação externa confirma a leitura: inspecionando a coluna pos, que ficou fora do treino, o cluster 2 é dominado por pivôs (C) e ala-pivôs.

O cluster 3 reúne os principais nomes ofensivos da liga, junto de outros jogadores de alta minutagem que não possuem o status de superestrelas, independentemente da posição declarada, de armadores como Luka Doncic e Shai Gilgeous-Alexander a pivôs como Nikola Jokic e Victor Wembanyama. Ou seja: o modelo agrupa por função em quadra, não por rótulo conforme o objetivo declarado.

7.2 Interpretabilidade do modelo

A interpretabilidade é cumprida pela análise dos centroides: como os dados foram padronizados, o vetor de centroide de cada cluster já expressa, em unidades de desvio padrão, o quanto aquele grupo está acima ou abaixo da média em cada variável. O heatmap da Figura 3 é, nesse sentido, o análogo de um gráfico de importância de atributos: ele mostra que mp_per_game, fga_per_game e pts_per_game separam principalmente os grupos ao longo do eixo de volume, enquanto fg_percent, blk_per_game e x3p_per_game separam interior de perímetro. A dominância do eixo de volume é confirmada pelo PCA: a primeira componente sozinha explica 54,97% da variância.

7.3 Justificativa do K = 4

É importante registrar que a escolha de K = 4 não decorreu de um critério estatístico único aplicado, em K = 2 a métrica é a melhor (0,3383), mas o modelo apenas separa "joga muito" de "joga pouco", perdendo por completo a distinção entre perfil interior e perimetral. É uma solução metricamente superior e analiticamente pobre, e, a partir de K = 5 o Silhouette cai de forma consistente (0,1868 em K = 5, 0,1442 em K = 10) enquanto a inércia continua diminuindo. Isso caracteriza fragmentação: o modelo passa a subdividir regiões contínuas do espaço, produzindo grupos cada vez menos distinguíveis entre si, sem ganho interpretativo.

K = 4 corresponde ao máximo local da curva de Silhouette na faixa $K \geq 3$, situa-se na região de flexão da curva de inércia e produz grupos com perfis estatísticos nitidamente diferentes, não redundantes e de fácil leitura no domínio. Em outras palavras: a métrica interna sozinha recomendaria K = 2, mas a métrica interna não sabe o que é basquete.

7.4 Limitações identificadas

Separação fraca entre grupos, o Silhouette de 0,2421 indica estrutura real, porém com fronteiras difusas e sobreposição considerável, visível também na dispersão contínua da projeção PCA. O desempenho de jogadores de basquete forma um espectro, não categorias discretas, jogadores próximos das fronteiras podem mudar de cluster com pequenas variações nos dados.

Viés de minutagem, estatísticas por jogo podem confundir qualidade com oportunidade. Um jogador talentoso com 8 minutos por partida cai no cluster 0 junto com veteranos em fim de carreira. Métricas ajustadas por posse (por 36 minutos ou por 100 posses) possivelmente mitigariam esse efeito e são uma extensão natural do trabalho.

Não foi aplicado filtro mínimo de jogos ou de minutos, o que injeta ruído no cluster 0.

Imputar a mediana em x3p_percent para jogadores que nunca tentaram um arremesso de três atribui eles um aproveitamento fictício de nível mediano, aproximando-os artificialmente de arremessadores, acrescentar uma variável indicadora de "não tentou", pode ser uma solução.

Sensibilidade a outliers, por minimizar distâncias quadráticas, o K-Means é puxado pelos valores extremos que optamos por preservar. Os centroides do cluster 3 são, portanto, deslocados para cima pela presença dos superastros.

Não foi executada análise de estabilidade por reamostragem (bootstrap ou múltiplas sementes), que quantificaria com que frequência dois jogadores caem no mesmo grupo sob perturbações dos dados.


8. Demonstração de funcionamento

```
python player_per_game_ia2.py
```

```
=====
36. RESUMO FINAL
=====

Temporada analisada: 2026
Jogadores analisados: 582
Clusters utilizados: 4
Silhouette Score final: 0.2421
Inércia final: 4305.66
Cluster do jogador hipotético: 3

Quantidade de jogadores por cluster:
Cluster 0: 222 jogadores
Cluster 1: 206 jogadores
Cluster 2: 67 jogadores
Cluster 3: 87 jogadores
```



8.1 Exemplo de resultado: atribuição de um jogador não visto

Para demonstrar o uso prático do modelo, um jogador hipotético foi submetido ao mesmo pipeline de imputação e padronização e classificado com `modelo_final.predict()`. Perfil de entrada: 30,0 minutos; 8,0/16,0 arremessos (FG% 0,500); 2,5/7,0 bolas de três (35,7%); 4,0/5,0 lances livres (80,0%); 7,0 rebotes; 5,0 assistências; 1,2 roubos; 0,8 tocos; 2,5 erros; 22,5 pontos.

Cluster	Distância ao centroide	Resultado
0	8,8070	
1	5,4868	
2	6,2299	
3	1,3409	Cluster atribuído

Tabela 9 — Distância do jogador de teste a cada centroide.

A atribuição é inequívoca: a distância ao centroide do cluster 3 (1,34) é quatro vezes menor que a do segundo colocado (5,49), o que indica que o perfil de entrada cai bem dentro do núcleo do grupo, e não em uma zona de fronteira. O resultado é coerente com o esperado, um jogador de 22,5 pontos, 7 rebotes e 5 assistências em 30 minutos é, por definição, um protagonista ofensivo.

Jogador	Time	Pos	PTS	REB	AST	MIN	Distância
Brandon Ingram	TOR	SF	21,5	5,6	3,7	33,8	2,018
Brandon Miller	CHO	SF	20,2	4,9	3,3	30,3	2,290
Kevin Durant	HOU	SF	26,0	5,5	4,8	36,4	2,293
Pascal Siakam	IND	PF	24,0	6,6	3,8	33,2	2,323
Desmond Bane	ORL	SG	20,1	4,1	4,1	33,6	2,344
Trey Murphy III	NOP	SF	21,5	5,7	3,8	35,5	2,450
Michael Porter Jr.	BRK	SF	24,2	7,1	3,0	32,5	2,460
Cooper Flagg	DAL	SF	21,0	6,7	4,5	33,5	2,508
Jayson Tatum	BOS	PF	21,8	10,0	5,3	32,6	2,519
Nickeil Alexander-Walker	ATL	SG	20,8	3,4	3,7	33,4	2,538

Tabela 10 — Dez jogadores reais mais próximos do perfil hipotético (jogadores_mais_proximos_teste.csv).

Esta tabela é a demonstração mais direta da utilidade prática da solução: dado um perfil estatístico desejado, o sistema devolve os jogadores reais mais semelhantes, ordenados por distância no espaço padronizado. O resultado é consistente do ponto de vista do domínio, a lista é composta majoritariamente por alas (SF/PF) pontuadores de volume intermediário, exatamente o arquétipo descrito na entrada.

8.2 Arquivos gerados

Arquivo	Conteúdo
avaliacao_k.csv	Silhouette e inércia para K de 2 a 12
silhouette_por_k.png	Gráfico do Silhouette Score por K
cotovelo_kmeans.png	Gráfico da inércia (método do cotovelo)
perfil_clusters.csv	Média das 16 estatísticas por cluster
perfil_clusters_heatmap.png	Heatmap dos perfis padronizados
clusters_pca.png	Projeção bidimensional dos clusters
jogadores_por_cluster.csv	Todos os 582 jogadores com estatísticas e cluster
jogadores_representativos.csv	Cinco jogadores mais próximos do centro de cada cluster
resultado_clusterizacao_nba_2026.csv	Resultado completo da clusterização
jogadores_mais_proximos_teste.csv	Jogadores reais mais próximos do perfil de teste

Tabela 11 — Arquivos produzidos na pasta outputs/.

9. Reprodutibilidade e harness da solução

9.1 Como reproduzir os experimentos

Passos:

1. Criar e ativar ambiente virtual

```
python -m venv .venv  
source .venv/bin/activate # Windows: .venv\Scripts\activate
```

2. Instalar dependências

```
pip install -r requirements.txt
```

3. Executar

```
python player_per_game_ia2.py
```

Dependências (requirements.txt): pandas, numpy, matplotlib, seaborn, scikit-learn.

Com `random_state = 42` e `n_init = 10`, execuções repetidas sobre o mesmo CSV produzem clusters idênticos, incluindo a numeração dos rótulos. Todos os números apresentados neste relatório podem ser reobtidos executando o script sem qualquer alteração.

Parâmetros configuráveis: ARQUIVO, TEMPORADA (padrão 2026), NUM_CLUSTERS (padrão 4), K_MIN/K_MAX (padrão 2 e 12) e RANDOM_STATE (padrão 42). Alterar apenas TEMPORADA reproduz toda a análise para outro ano.

9.2 Harness: contexto, regras e validações

O script foi organizado como um pipeline linear com pontos de verificação explícitos, de modo que uma execução mal sucedida falhe de forma imediata e informativa, em vez de produzir resultados silenciosamente incorretos.

Elemento	Implementação
Contexto	Bloco de configuração centralizado no topo do arquivo; nenhum parâmetro fica codificado no meio da lógica
Validação de entrada	Verificação da existência do CSV antes de qualquer processamento, com <code>FileNotFoundError</code> e mensagem orientando onde colocar o arquivo
Validação de esquema	Conferência de que todas as 16 features existem no <code>DataFrame</code> ; <code>ValueError</code> listando nominalmente as ausentes
Validação de integridade	Contagem e impressão de registros antes e depois de cada filtro, de jogadores com múltiplos registros e de duplicatas, permitindo auditar o funil de dados
Validação de tratamento	Recontagem de valores ausentes após a imputação, confirmando o total zerado
Consistência do pipeline	O mesmo imputer e o mesmo scaler ajustados no treino são reaplicados ao jogador hipotético, garantindo que dados novos passem por transformação idêntica
Rastreabilidade	Cada etapa imprime um cabeçalho numerado no console e persiste seus resultados em CSV ou PNG na pasta <code>outputs/</code>
Determinismo	Semente fixa e <code>n_init=10</code> em todos os modelos treinados

Tabela 12 — Estrutura do harness da solução.

10. Conclusão

O trabalho entregou uma clusterização funcional dos 582 jogadores da NBA na temporada 2026 em quatro perfis interpretáveis, obtida exclusivamente a partir de estatísticas de desempenho e sem qualquer informação de posição. O resultado mais significativo é que o modelo separa jogo interior de jogo perimeteral entre atletas de minutagem e pontuação quase idênticas, o que confirma que a estrutura encontrada reflete função em quadra e não apenas volume de participação. As métricas internas (Silhouette de 0,2421) são modestas e foram interpretadas honestamente, e a escolha de $K = 4$ privilegiou interpretabilidade sobre o ótimo métrico, que ocorreria em $K = 2$ com perda completa de valor analítico. Os próximos passos naturais são a adoção de estatísticas ajustadas por posse, a aplicação de um filtro mínimo de minutos e a avaliação da estabilidade dos grupos por reamostragem.